

Modelos Lineales


Mtro. René Rosado González
Director de Programa LTP

Modelos Lineales



Fénomeno observado

$$Y = f(x) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n$$


Modelos Lineales



Regresión Lineal



Regresión Lineal Simple



$$y = x\beta$$

$$\begin{aligned} y_1 &= \beta_1 + \beta_2 x_{1,1} \\ y_2 &= \beta_1 + \beta_2 x_{1,2} \\ \dots &\dots \\ y_n &= \beta_1 + \beta_2 x_{1,n} \end{aligned}$$



$$\hat{y} = x\hat{\beta} + \epsilon$$

$$\epsilon \sim N(0, \sigma_\epsilon^2 I)$$

- Homocedasticidad.
- Normalidad de los errores
- No correlación entre los errores

Ajuste por Mínimos Cuadrados Ordinarios



$$\min(f(y - \hat{y})) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = S$$

Condición de Primer Orden

$$\frac{\delta S}{\delta \beta_i} = 0$$

$$\beta_1^* = \bar{y} - b\bar{x}$$

$$\beta_2^* = \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$



El Intercepto

$$S = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - \beta_1 - \beta_2 x_i)^2$$

$$\frac{\partial S}{\partial \beta_1} = 2 \sum_{i=1}^n (y_i - \beta_1 - \beta_2 x_i) = 0$$

$$\beta_1^* = \bar{y} - \beta_2 \bar{x}$$

La Pendiente

$$S = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - \beta_1 - \beta_2 x_i)^2$$

$$\frac{\partial S}{\partial \beta_2} = 2 \sum_{i=1}^n (y_i - \beta_1 - \beta_2 x_i) x_i = 2 \sum_{i=1}^n (y_i - (\bar{y} - \beta_2 \bar{x}) - \beta_2 x_i) x_i =$$

$$2 \sum_{i=1}^n ((y_i - \bar{y}) + \beta_2(\bar{x} - x_i)) x_i = 2 \sum_{i=1}^n (y_i - \bar{y}) x_i + \beta_2(\bar{x} - x_i) x_i = 0$$

$$\beta_2^* = \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{cov(y, x)}{var(x)}$$


Un ejemplo



Modelos con interacciones

Diferentes interceptos


$$y = \alpha + \beta x + \delta i \\ = (\alpha + \delta i) + \beta x$$




$$i \begin{cases} 1 & \text{si clase } A \\ 0 & \text{otra clase} \end{cases}$$

Diferentes Pendientes

$$y = \alpha + \beta x + \delta i * x \\ = \alpha + (\beta + \delta i)x$$



Regresión Lineal Múltiple



$$y = x\beta$$

$$\begin{aligned} y_1 &= \beta_0 + \beta_1 x_{1,1} + \dots + \beta_k x_{k,1} \\ y_2 &= \beta_0 + \beta_1 x_{1,2} + \dots + \beta_k x_{k,2} \\ \dots &\quad \dots & \dots \\ y_n &= \beta_0 + \beta_1 x_{1,n} + \dots + \beta_k x_{k,n} \end{aligned}$$



$$\hat{y} = x\hat{\beta} + \epsilon$$

$$\epsilon \sim N(0, \sigma_\epsilon^2 I)$$

- Homocedasticidad.
- Normalidad de los errores
- No correlación entre los errores

El Modelo Matricial

$$\begin{matrix} y_1 \\ y_2 \\ \dots \\ y_n \end{matrix} = \begin{matrix} \beta_1 \\ \beta_1 \\ \dots \\ \beta_1 \end{matrix} + \begin{matrix} \beta_2 x_{1,1} & \dots & \beta_k x_{k,1} \\ \beta_2 x_{1,2} & \dots & \beta_k x_{k,2} \\ \dots & \dots & \dots \\ \beta_2 x_{1,n} & \dots & \beta_k x_{k,n} \end{matrix} = \begin{bmatrix} 1 & x_{1,1} & \dots & x_{k,1} \\ 1 & x_{1,2} & \dots & x_{k,2} \\ \dots & \dots & \dots & \dots \\ 1 & x_{1,n} & \dots & x_{k,n} \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \dots \\ \beta_n \end{bmatrix}$$

$$\underline{y} = X\underline{\beta}$$

El Modelo Matricial

$$\underline{y} - \hat{\underline{y}} = \underline{\epsilon} = \underline{y} - X\underline{\beta}$$

$$S = \underline{\epsilon}^T \underline{\epsilon} = (\underline{y} - X\underline{\beta})^T (\underline{y} - X\underline{\beta}) = (\underline{y}^T - \underline{\beta}^T X^T) (\underline{y} - X\underline{\beta}) =$$

$$\underline{y}^T \underline{y} - \underline{y}^T X \underline{\beta} - X^T \underline{\beta}^T \underline{y} + \underline{\beta}^T X^T X \underline{\beta}$$

Condiciones de primer orden

$$\frac{\partial S}{\partial \underline{\beta}} = \begin{bmatrix} \frac{\partial S}{\partial \beta_1} \\ \vdots \\ \frac{\partial S}{\partial \beta_n} \end{bmatrix} = 0$$

El Modelo Matricial

$$\frac{\partial S}{\partial \underline{\beta}} = \frac{\left(\underline{y}^T \underline{y} - \underline{y}^T X \underline{\beta} - X^T \underline{\beta}^T \underline{y} + \underline{\beta}^T X^T X \underline{\beta} \right)}{\partial \underline{\beta}} = 0$$

$$= 0 - \frac{2 \left(\underline{y}^T X \underline{\beta} \right)}{\partial \underline{\beta}} + \frac{\left(\underline{\beta}^T X^T X \underline{\beta} \right)}{\partial \underline{\beta}}$$

$$= -2 \left(\underline{y}^T X \right) + 2(X^T X) \underline{\beta} = 0$$

$$\underline{\beta} = (X^T X)^{-1} (X^T y)$$

El Modelo Matricial (Bivariado)

$$\underline{\beta} = (X^T X)^{-1} (X^T y)$$

$$(X^T X) = \begin{bmatrix} 1 & \dots & 1 \\ x_1 & \dots & x_n \end{bmatrix} \begin{bmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix} = \begin{bmatrix} n & n\bar{x} \\ n\bar{x} & \sum_i x_i^2 \end{bmatrix}$$

$$(X^T X)^{-1} = \begin{bmatrix} \sum_i x_i^2 & -n\bar{x} \\ -n\bar{x} & n \end{bmatrix}$$


$$(X^T y) = \begin{bmatrix} 1 & \dots & 1 \\ x_1 & \dots & x_n \end{bmatrix} \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} n\bar{y} \\ \sum_i x_i y_i \end{bmatrix}$$

$$\underline{\beta} = \begin{bmatrix} \sum_i x_i^2 & -n\bar{x} \\ -n\bar{x} & n \end{bmatrix} \begin{bmatrix} n\bar{y} \\ \sum_i x_i y_i \end{bmatrix} = \frac{\sum_i^n x_i y_i - n\bar{x}\bar{y}}{\sum_i^n x_i^2 - n\bar{x}^2} = \frac{cov(y, x)}{var(x)}$$

Un ejemplo



Regresión Lineal Simple



$$y = x\beta$$

$$\begin{aligned} y_1 &= \beta_0 + \beta_1 x_{1,1} + \dots + \beta_k x_{k,1} \\ y_2 &= \beta_0 + \beta_1 x_{1,2} + \dots + \beta_k x_{k,2} \\ \dots &\dots \dots \dots \\ y_n &= \beta_0 + \beta_1 x_{1,n} + \dots + \beta_k x_{k,n} \end{aligned}$$




$$\hat{y} = x\hat{\beta} + \epsilon$$

$$\epsilon \sim N(0, \sigma_\epsilon^2 I)$$


- Homocedasticidad.
- Normalidad
- No correlación

Regresión Lineal Gaussiana





$$\hat{y} = x\hat{\beta} + \epsilon$$

$$\epsilon \sim N(0, \sigma_\epsilon^2 I)$$




¡René, mis residuales no son normales!




“Normality is a fine ideal for those who have no imagination”

- Carl Jung



Modelos Lineales Generalizados



Modelos Lineales Generalizados

- Son un tipo de modelado estadístico formulado por John Nelder y Robert Wedderburn en 1972.
- Es un término general que abarca muchos otros modelos, lo que permite que la variable de respuesta y tenga una distribución de error diferente a la distribución normal.
- Los modelos que cubriremos en este curso son
 - regresión lineal,
 - regresión de Poisson.
 - regresión logística


Modelos Lineales Generalizados

- Los datos deben ser independientes y aleatorios.
- Cada variable aleatoria tiene la misma distribución de probabilidad.
- La variable de respuesta tiene una distribución de una familia exponencial (por ejemplo, binomial, Poisson, multinomial, normal).
- La variable de respuesta original no necesita tener una relación lineal con las variables independientes, pero la variable de respuesta transformada en la liga canónica depende linealmente de las variables independientes.

Preguntas no normales

- ¿El número de muertes de motociclistas en un año determinado está relacionado con las leyes estatales sobre uso de cascos?
- ¿La cantidad de inasistencias durante un año difiere para las escuelas públicas y privadas?
- ¿El número diario de ingresos por asma a una Sala de Emergencias difiere según los índices de contaminación del aire?


Regresión Gaussiana



Preguntas Poisson

- ¿El número de muertes de motociclistas en un año determinado está relacionado con las leyes estatales sobre uso de cascos?
- ¿La cantidad de inasistencias durante un año difiere para las escuelas públicas y privadas?
- ¿El número diario de ingresos por asma a una Sala de Emergencias difiere según los índices de contaminación del aire?

Regresión Poisson



Regresión Poisson

Distribución Poisson:


$$\Pr(Y = k) = \frac{e^{-\lambda} \lambda^k}{k!}$$

s.a. $\lambda > 0$ y $\lambda = E(y) = Var(y)$

Liga canónica:

$$\lambda(x) = e^{\beta x} \Leftrightarrow \log(\lambda(x)) = \beta x$$

Distribución Poisson
Valores Lambda



Máxima Versosimilitud

La verosimilitud es una función que nos dice qué tan probable es que observemos nuestros datos para un valor de parámetro dado.

Supongamos que tenemos conteos observados de tamaño 4, 2, 8, 6 y 1:

$$\text{Verosimilitud} = \Pr(Y_1 = 4) * \Pr(Y_2 = 2) * \Pr(Y_3 = 8) * \Pr(Y_4 = 6) * \Pr(Y_5 = 1)$$

$$\text{Verosimilitud} = \frac{e^{-\lambda_1}\lambda_1^4}{4!} * \frac{e^{-\lambda_2}\lambda_2^2}{2!} * \frac{e^{-\lambda_3}\lambda_3^8}{8!} * \frac{e^{-\lambda_4}\lambda_4^6}{6!} * \frac{e^{-\lambda_5}\lambda_5^1}{1!} = \prod_i^N \frac{e^{-\lambda_i}\lambda_i^{y_i}}{y_i!}$$

$$-\text{Logversoimilitud} =$$

$$-\log L \propto \lambda_1 - 4 \log(\lambda_1) + \lambda_2 - 2 \log(\lambda_2) + \lambda_3 - 8 \log(\lambda_3) + \lambda_4 - 6 \log(\lambda_4) + \lambda_5 - 1 \log(\lambda_5)$$

$$\log L \propto \sum_i^N -\lambda_i + y_i \log(\lambda_i) = \sum_i^n -e^{\beta_0 + \beta_1 x_i} + y_i \log(\beta_0 + \beta_1 x_i)$$

Regresión Poisson

Distribución Poisson:


$$\Pr(Y = k) = \frac{e^{-\lambda} \lambda^k}{k!}$$

s.a. $\lambda > 0$ y $\lambda = E(y) = Var(y)$

Liga canónica:

$$\lambda(x) = e^{\beta x} \Leftrightarrow \log(\lambda(x)) = \beta x$$

Distribución Poisson
Valores Lambda



Regresión Poisson

Supuestos

1. Respuesta de Poisson

La variable de respuesta es un conteo por unidad de tiempo o espacio, descrita por una distribución de Poisson.

2. Independencia


Las observaciones deben ser independientes entre sí.

3. La media es igual a la varianza


Por definición, la media de una variable aleatoria tipo Poisson debe ser igual a su varianza.

4. Linealidad

El logaritmo de la tasa media, $\log(\lambda)$, debe ser una función lineal de x .



Regresión Poisson



Regresión Poisson

Interpretación

Ya que nuestro modelo tiene la siguiente forma:

$$\log(\lambda) = \beta_0 + \beta_1 x + \epsilon$$


resulta más fácil interpretarlo si lo regresamos a su forma original

$$\lambda = e^{\beta_0 + \beta_1 x + \epsilon} = e^{\beta_0} e^{\beta_1 x} e^{\epsilon}$$

de esta forma:

e^{β_0} : es el conteo base cuando $x = 0$

e^{β_1} : es el factor multiplicativo en el que cambia el conteo ante un cambio en x (relación de tasa de incidencia)



Criterios de Información

Para la selección de nuestro λ utilizaremos los criterios de Akaike (AIC) y Schwarz (BIC). Ambos introducen una penalización en función del número de parámetros en el modelo, evitando así un sobre ajuste excesivo derivado de introducir muchas variables.



$$AIC = n * \log(\epsilon^2) + 2 * \text{Grados de Libertad}$$

$$BIC = n * \log(\epsilon^2) + 2 * \text{Grados de Libertad} * \log(n)$$

Un ejemplo



Varianza de los Parámetros



Regularización

Cuando los coeficientes presentan problemas de varianza podemos imponer restricciones en sus rangos

$$\min(f(\hat{y} - y)) + \lambda \sum_{j=1}^p h(\beta_j)$$


Definimos un valor de $\lambda > 0$ para mejorar nuestro modelo en función de su capacidad predictiva:

- Incrementar el valor de λ implica aumentar el sesgo de nuestro modelo pero reducir su varianza.
- Dado lo anterior, se asume que los regresores pueden ser escalados (estandarizados a z-scores)

Regularización LASSO

Regularización L1


$$L_{LASSO}(\hat{\beta}) = L_1(\hat{\beta}) = \sum_{i=1}^n (y_i - x_i \hat{\beta})^2 + \lambda \sum_{j=1}^p |\hat{\beta}_j| = \left\| y_i - x_i \hat{\beta} \right\|^2 + \lambda |\hat{\beta}|$$



Regularización RIDGE

Regularización L2

$$L_{Ridge}(\hat{\beta}) = L_2(\hat{\beta}) = \sum_{i=1}^n (y_i - x_i \hat{\beta})^2 + \lambda \sum_{j=1}^p \hat{\beta}_j^2 = \left\| y_i - x_i \hat{\beta} \right\|^2 + \lambda \left\| \hat{\beta} \right\|^2$$



$$\hat{\beta}_R^* = (x^T x + \lambda I)^{-1} x^T y$$

Regularización RIDGE Heterocedastica

En lugar de resolver el problema de heteroscedasticidad igualando las varianzas de todos los predictores a través de escalarlos, podemos usarlos como pesos en el proceso de estimación.

$$L_{RH}(\hat{\beta}) = L_{2H}(\hat{\beta}) = \sum_{i=1}^n (y_i - x_i \hat{\beta})^2 + \lambda \sum_{j=1}^p w_j \hat{\beta}_j^2 = \|y_i - x_i \hat{\beta}\|^2 + \lambda \|w_j \hat{\beta}\|^2$$



Simplemente hacemos una regresión univariada para cada uno de los predictores. A partir de ello, extraemos la varianza de cada coeficiente $\hat{\sigma}_{\beta}^2$ y la utilizamos como ponderador.

$$\frac{1}{\hat{\sigma}_{\beta}^2} = w$$

Los coeficientes con varianzas más altas (mayor incertidumbre) son por lo tanto más penalizados


RIDGE vs LASSO

- No restringido al origen.
- Permite atender multicolinealidad y heterocedasticidad encogiendo los coeficientes.
- Permite excluir variables del modelo.
- Reduce la varianza al desechar variables ruidosas o redundantes.




Resumen

Estimadores Regularizados vs. Estimadores OLS



Regularización Mixta

$$L_{Mix}(\hat{\beta}) = \sum_{i=1}^n (y_i - x_i \hat{\beta})^2 + \lambda \left(\alpha \sum_{j=1}^p \hat{\beta}_j^2 + (1 - \alpha) \sum_{j=1}^p |\hat{\beta}_j| \right) = \left\| y_i - x_i \hat{\beta} \right\|^2 + \lambda \left(\alpha \left\| \hat{\beta} \right\|^2 + (1 - \alpha) \left\| \hat{\beta} \right\| \right)$$




Un ejemplo



Preguntas no normales

- ¿Con qué probabilidad un partido puede ganar cierto distrito electoral?
- ¿Cuál es la probabilidad de que una persona reincida en un acto delectivo?
- ¿Cómo podemos detectar actos de corrupción o fraudes?


Regresión Gaussiana




Preguntas Categóricas

- ¿Con qué probabilidad un partido puede ganar cierto distrito electoral?
- ¿Cuál es la probabilidad de que una persona reincida en un acto delectivo?
- ¿Cómo podemos detectar actos de corrupción o fraudes?

Regresión Lógistica



Modelos Lineales Generalizados



Liga Logística

Podemos definir la probabilidad de $y = 1$ como

$$P(Y = 1 | X = x) = \frac{e^{x\beta}}{1 + e^{x\beta}}$$

y su complemento como:

$$P(Y = 0 | X = x) = 1 - P(Y = 1 | X = x) = \frac{1}{1 + e^{x\beta}}$$

Si calculamos la razón de probabilidades obtenemos algo así

$$\frac{P(Y = 1)}{P(Y = 0)} = \frac{p(x)}{1 - p(x)} = e^{\beta x}$$

La log-razón de probabilidades es lineal en x . A esta función se le conoce como liga logística

$$y = \log\left(\frac{p(x)}{1 - p(x)}\right) = \beta x$$

Regresión Logística

Supuestos

1. Respuesta categórica

La variable respuesta es catagórica o suma de respuestas catagórica.

2. Independencia

Las observaciones deben ser independientes entre sí.


3. Varianza estructurada

Por definición la varianza de una variable binomial está dada por $np(1 - p)$

4. Linealidad

La log-razón de probabilidades es lineal en x .

$$y = \log\left(\frac{p(x)}{1 - p(x)}\right) = \beta x$$



Un ejemplo



Matriz de Confusión



Clasificado

Positivo

Negativo



Observados

Positivo

Verdaderos Positivos (VP)

Falsos Negativos (FN)
(Error tipo II)

Negativo

Falsos Positivos (FP)
(Error tipo I)

Verdaderos Negativos (VN)

Métricas para Clasificación

Exactitud

- $$\frac{VP+VN}{VP+VN+FP+FN}$$

Precisión

- $$\frac{VP}{VP+FP}$$

Sensibilidad

(Tasa de Verdaderos Positivos)

- $$\frac{VP}{VP+FN}$$

Tasa de Falsos Positivos

(Error Tipo I)

- $$\frac{FP}{VP+FP}$$

Especificidad

(Tasa de Verdaderos Negativos)

- $$\frac{VN}{VN+FP}$$

Tasa de Falsos Negativos

(Error Tipo II)

- $$\frac{FN}{VN+FN}$$

Puntaje F-Beta

$$F_{\beta} = (1 + \beta^2) * \frac{\text{precisión} * \text{sensibilidad}}{(\beta^2 * \text{precisión}) + \text{sensibilidad}}$$

$$F_1 = 2 * \frac{\text{precisión} * \text{sensibilidad}}{\text{precisión} + \text{sensibilidad}}$$

$$F_2 = 5 * \frac{\text{precisión} * \text{sensibilidad}}{(4 * \text{precisión}) + \text{sensibilidad}}$$


...

Al elegir beta en su puntaje F-beta, cuanto más nos importe la sensibilidad sobre la precisión, debemos elegir una beta más alta.

Por ejemplo, con la puntuación F1, nos preocupamos por igual por la sensibilidad y la precisión.


Con la puntuación F2, la sensibilidad es el doble de importante para nosotros.

Área Bajo la Curva Característica Operativa del Receptor




Tipos de Paneles

Balanceado



Desbalanceado



Un ejemplo

